

Содержание

Занятие 4. Субградиентный метод и адаптивные методы оптимизации	1
1. Мотивация	1
2. M -липшицевость	1
3. Субградиент и субдифференциал	1
4. Субградиентный метод	2
5. Адаптивные методы	3
6. Дополнительные направления	4
7. Ключевые формулы	5

Занятие 4. Субградиентный метод и адаптивные методы оптимизации

1. Мотивация

Задача оптимизации: $\min_{x \in \mathbb{R}^d} f(x)$.

Градиентный спуск: $x_{k+1} = x_k - \gamma_k \nabla f(x_k)$, $\gamma_k > 0$.

Для гладких L -гладких выпуклых функций GD сходится со скоростью $O(1/K)$; для μ -сильно выпуклых — $O((1 - \mu\gamma)^K)$.

Функции вида $|x|$, $\|x\|_1$, $\|Ax\|_1$, $\lambda_{\max}(X)$, $\max(0, x)$ не являются L -гладкими: в «угловых» точках градиент не определён. Для $|x|$ при $y = \delta$, $x = -\delta$, $\delta > 0$ из условия L -гладкости следует $L \geq 1/\delta \rightarrow +\infty$ при $\delta \rightarrow 0^+$.

Теоретический шаг GD $\gamma \sim 1/L$ требует конечной константы L ; для негладких функций классическая теория GD неприменима напрямую.

2. M -липшицевость

Определение. Функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ — M -липшицева, если

$$|f(y) - f(x)| \leq M\|y - x\| \quad \forall x, y \in \mathbb{R}^d,$$

где $M > 0$ — константа Липшица.

M -липшицевая функция не может быть μ -сильно выпуклой на всём $\mathbb{R}^d$: параболический рост $\sim \|y - x\|^2$ несовместим с линейной мажорантой $|f(y) - f(x)| \leq M\|y - x\|$.

3. Субградиент и субдифференциал

Определение. Вектор $g \in \mathbb{R}^d$ — субградиент выпуклой f в точке x , если

$$f(y) \geq f(x) + \langle g, y - x \rangle \quad \forall y \in \mathbb{R}^d.$$

Субдифференциал: $\partial f(x) = \{g \in \mathbb{R}^d : g \text{ — субградиент } f \text{ в } x\}$.

Условие оптимальности (выпуклая f):

$$0 \in \partial f(x) \iff x \text{ — точка глобального минимума.}$$

Теорема. Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R}$ выпукла. Тогда эквивалентно:

$$f \text{ — } M\text{-липшицева} \iff \forall x \in \mathbb{R}^d, \forall g \in \partial f(x) : \|g\| \leq M.$$

4. Субградиентный метод

Алгоритм:

$$x_{k+1} = x_k - \gamma_k g_k, \quad g_k \in \partial f(x_k).$$

На каждом шаге допускается произвольный выбор элемента субдифференциала.

Предположения для анализа сходимости: f выпуклая, M -липшицева; $x^* \in \arg \min f$; $R_0 = \|x_0 - x^*\|$; $\|g_k\| \leq M$.

Оценка одной итерации. Из раскрытия $\|x_{k+1} - x^*\|^2$ и субградиентного неравенства:

$$\|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2 - 2\gamma_k(f(x_k) - f^*) + \gamma_k^2 M^2.$$

Телескопическая сумма при постоянном шаге $\gamma_k = \gamma$:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x_k) - f^*) \leq \frac{R_0^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Неравенство Йенсена. Для выпуклой f и весов $\alpha_k = 1/K$:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x_k\right) \leq \frac{1}{K} \sum_{k=0}^{K-1} f(x_k).$$

Средняя итерация: $\bar{x}_K = \frac{1}{K} \sum_{k=0}^{K-1} x_k$.

Оценка недостатка:

$$f(\bar{x}_K) - f^* \leq \frac{R_0^2}{2\gamma K} + \frac{\gamma M^2}{2} = \varphi(\gamma).$$

Оптимальный постоянный шаг: $\gamma^* = \frac{R_0}{M\sqrt{K}}$.

Скорость сходимости: $f(\bar{x}_K) - f^* = O\left(\frac{MR_0}{\sqrt{K}}\right) = O(1/\sqrt{K})$.

Убывающий шаг: $\gamma_k = \frac{R_0}{M\sqrt{k+1}}$ даёт ту же скорость $O(1/\sqrt{K})$ по среднему недостатку.

Сравнение с GD: для гладких выпуклых функций GD даёт $O(1/K)$ по последней точке; субградиентный метод требует усреднения $\bar{x}_K$ и сходится медленнее.

5. Адаптивные методы

Теоретический шаг $\gamma_k = R_0/(M\sqrt{k+1})$ требует знания M и R_0 . На практике оба параметра неизвестны.

Эвристика: замена $M\sqrt{k+1}$ на $\sqrt{\sum_{t=0}^k \|g_t\|^2}$. Для устранения деления на ноль добавляется $b > 0$.

AdaGrad-Norm (Streeter, 2010; Duchi et al., 2011)

$$b_k^2 = b_{k-1}^2 + \|g_k\|^2, \quad b_{-1} = 0, \quad b_k > 0;$$

$$x_{k+1} = x_k - \frac{R_0}{b_k} g_k.$$

Скалярная адаптация шага; знаменатель монотонно растёт.

Покоординатный AdaGrad

$$b_{k,i}^2 = b_{k-1,i}^2 + g_{k,i}^2; \quad x_{k+1,i} = x_{k,i} - \frac{R_0}{b_{k,i}} g_{k,i}.$$

Каждая координата имеет собственный знаменатель. Недостаток: $b_{k,i}$ только растёт, шаги затухают на длинных траекториях.

RMSProp-Norm (Tieleman, 2012)

$$v_k^2 = \beta_2 v_{k-1}^2 + (1 - \beta_2) \|g_k\|^2, \quad \beta_2 \in (0, 1);$$

$$x_{k+1} = x_k - \frac{D}{v_k} g_k.$$

Экспоненциальное сглаживание вместо полной суммы; знаменатель не растёт бесконечно.

Adam-Norm (Kingma & Ba, 2014)

$$\begin{aligned}
m_k &= \beta_1 m_{k-1} + (1 - \beta_1) g_k, \quad m_{-1} = 0; \\
v_k^2 &= \beta_2 v_{k-1}^2 + (1 - \beta_2) \|g_k\|^2; \\
x_{k+1} &= x_k - \frac{D}{v_k} m_k.
\end{aligned}$$

При $\beta_1 = 0$ вырождается в RMSProp. Типичные значения: $\beta_1 = 0.9$, $\beta_2 = 0.999$.

AMSGrad (Reddi et al., 2018)

$$\begin{aligned}
\hat{v}_k^2 &= \beta_2 v_{k-1}^2 + (1 - \beta_2) \|g_k\|^2; \\
v_k^2 &= \max(v_{k-1}^2, \hat{v}_k^2).
\end{aligned}$$

Принудительная монотонность v_k^2 ; устраняет возможность расходимости Adam при $\beta_2 < 1$ на стохастических выпуклых задачах.

AdamW (Loshchilov & Hutter, 2017)

$$x_{k+1} = (1 - \lambda_k) x_k - \frac{D}{v_k} m_k.$$

Развязанный weight decay: регуляризация $\|x\|_2^2$ применяется отдельно от адаптивного шага Adam.

6. Дополнительные направления

NAdam — комбинация Nesterov-ускорения с Adam; момент вычисляется с экстраполяцией.

Sophia (2023) — стохастическая оптимизация с диагональной оценкой гессииана для адаптивного масштабирования шага.

D-Adaptation (2022) — parameter-free метод; автоматическая оценка R_0 без ручного выбора масштаба шага.

Robbins-Monro (1951) — условия на шаг в стохастическом GD:

$$\sum_{k=0}^{\infty} \gamma_k = +\infty, \quad \sum_{k=0}^{\infty} \gamma_k^2 < +\infty.$$

Шаг $\gamma_k = 1/k$ удовлетворяет обоим условиям; $\gamma_k = 1/\sqrt{k}$ — нет.

7. Ключевые формулы

- Субградиент: $f(y) \geq f(x) + \langle g, y - x \rangle$
- Оптимальность: $0 \in \partial f(x) \iff x$ — глобальный минимум
- M -липшицевость: $|f(y) - f(x)| \leq M\|y - x\|$
- Эквивалентность: f M -липшицева $\iff \|g\| \leq M \forall g \in \partial f(x)$
- Субградиентный шаг: $x_{k+1} = x_k - \gamma_k g_k, g_k \in \partial f(x_k)$
- Средняя итерация: $\bar{x}_K = \frac{1}{K} \sum_{k=0}^{K-1} x_k$
- Оценка недостатка: $f(\bar{x}_K) - f^* \leq \frac{R_0^2}{2\gamma K} + \frac{\gamma M^2}{2}$
- Оптимальный шаг: $\gamma^* = \frac{R_0}{M\sqrt{K}}$
- Скорость: $O(MR_0/\sqrt{K})$
- Убывающий шаг: $\gamma_k = \frac{R_0}{M\sqrt{k+1}}$
- AdaGrad-Norm: $b_k^2 = b_{k-1}^2 + \|g_k\|^2; x_{k+1} = x_k - (R_0/b_k) g_k$
- Покоординатный AdaGrad: $b_{k,i}^2 = b_{k-1,i}^2 + g_{k,i}^2$
- RMSProp-Norm: $v_k^2 = \beta_2 v_{k-1}^2 + (1 - \beta_2) \|g_k\|^2$
- Adam: $m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k; v_k^2 = \beta_2 v_{k-1}^2 + (1 - \beta_2) \|g_k\|^2$
- AMSGrad: $v_k^2 = \max(v_{k-1}^2, \beta_2 v_{k-1}^2 + (1 - \beta_2) \|g_k\|^2)$
- AdamW: $x_{k+1} = (1 - \lambda_k) x_k - (D/v_k) m_k$
- Robbins-Monro: $\sum \gamma_k = \infty; \sum \gamma_k^2 < \infty$